

OntoTriage: Sistema Especialista de Apoio à Triage Clínica Baseado em Knowledge Graph e GraphRAG

Henrique de Andrade França¹

¹Centro de Informática – Universidade Federal da Paraíba (UFPB)
58.058-600 – João Pessoa – PB – Brasil

henrique.andrade@academico.ufpb.br

Abstract. *This paper describes the development of OntoTriage, an expert system for clinical triage support that mitigates the hallucination risks of Large Language Models (LLMs) using a GraphRAG architecture. Medical knowledge was structured in a Knowledge Graph using RDF/OWL and OWL-RL inference, strictly grounded in official sources (Ministry of Health and ANVISA). The system incorporates information traceability through the PROV-O ontology, dynamically retrieving associated provenance via SPARQL queries to anchor the LLM's response synthesis.*

Resumo. *Este artigo descreve o desenvolvimento do OntoTriage, um sistema especialista voltado ao apoio à triagem clínica, que mitiga o risco de alucinações de Modelos de Linguagem de Grande Escala (LLMs) por meio da arquitetura GraphRAG. O conhecimento médico foi estruturado em um Knowledge Graph utilizando RDF/OWL e inferência OWL-RL, fundamentado estritamente em fontes oficiais (Ministério da Saúde e ANVISA). O sistema incorpora rastreabilidade das entidades do conhecimento através da ontologia PROV-O, recuperando dinamicamente suas fontes associadas via SPARQL para ancorar a síntese de respostas do LLM.*

1. Introdução

A sobrecarga dos sistemas de saúde contemporâneos demanda soluções tecnológicas capazes de realizar triagens iniciais rápidas e seguras. Embora os Modelos de Linguagem de Grande Escala (LLMs) possuam notável capacidade de compreensão e geração de linguagem natural, seu uso autônomo no domínio médico é crítico devido à propensão a "alucinações" — a geração de informações plausíveis, porém factualmente incorretas. Na área da saúde, recomendações infundadas ou a omissão de contraindicações medicamentosas apresentam riscos diretos à integridade do paciente.

Para solucionar essa limitação técnica, é necessário restringir a geração do LLM a uma base de conhecimento factual, estruturada e verificável. A abordagem Retrieval-Augmented Generation (RAG) tem sido amplamente adotada; contudo, o RAG vetorial tradicional frequentemente falha em capturar relações semânticas complexas, como hierarquias de sintomas e interdependências lógicas entre doenças e contraindicações.

Neste contexto, este trabalho apresenta o OntoTriage, um Sistema Baseado em Conhecimento (SBC) que adota a arquitetura GraphRAG. O sistema combina Inteligência Artificial Simbólica (Ontologias e Inferência Lógica) com IA Conexcionista

(LLMs) para fornecer apoio informacional à triagem clínica. O objetivo principal é receber o relato não estruturado de um usuário, mapear os sintomas relatados, consultar um Knowledge Graph (KG) estritamente fundamentado em protocolos oficiais e gerar uma resposta fundamentada a partir das informações e fontes associadas às entidades recuperadas do KG.

2. Modelagem do Conhecimento

O núcleo simbólico do OntoTriage consiste em um Knowledge Graph modelado nativamente através da biblioteca Python `rdflib`. A base foi construída utilizando as recomendações do W3C (RDF, RDFS e OWL) e serializada no formato Turtle (`ontology.ttl`), garantindo legibilidade e interoperabilidade semântica.

2.1. Esquema da Ontologia

A ontologia foi definida em torno de quatro classes fundamentais (`owl:Class`), que representam as entidades de domínio:

- `onto:Doenca`: Representa as condições clínicas (ex.: Dengue, Zika, COVID-19).
- `onto:Sintoma`: Representa as manifestações reportadas.
- `onto:Medicamento`: Representa os fármacos (ex.: Ibuprofeno, Paracetamol, AAS).
- `onto:CategoriaTerapeutica`: Agrupa os medicamentos semanticamente (ex.: AINE, Analgésico).

As relações entre estas classes foram estabelecidas por meio de `owl:ObjectProperty`, definindo explicitamente o domínio e a imagem (`rdfs:domain` e `rdfs:range`):

- `onto:apresentaSintoma`: Relaciona Doenca a Sintoma.
- `onto:indicadoPara`: Relaciona Medicamento a Sintoma.
- `onto:contraindicadoPara`: Relaciona Medicamento a Doenca.
- `onto:pertenceACategoria`: Relaciona Medicamento a CategoriaTerapeutica.

Para conferir capacidade de raciocínio taxonômico ao sistema, foram implementadas hierarquias. Por exemplo, a classe `SintomaRespiratorio` foi definida como subclasse de `Sintoma` (`rdfs:subClassOf`).

2.2. Rastreabilidade e Proveniência

Uma exigência arquitetural do sistema é reduzir o risco de geração de referências bibliográficas não fundamentadas no conhecimento recuperado. Para isso, a ontologia PROV-O do W3C foi integrada ao grafo.

As fontes de dados foram instanciadas como `prov:Entity`, possuindo rótulos legíveis (`rdfs:label`) e descrições (`rdfs:comment`). O sistema conta com duas fontes primárias:

1. Ministério da Saúde: Protocolos de Manejo Clínico (modelado como `onto:Fonte_MS_Protocolos`).
2. ANVISA: Bulário Eletrônico (modelado como `onto:Fonte_ANVISA_Bulario`).

As entidades de doenças são associadas à fonte do Ministério da Saúde e as entidades de medicamentos à fonte da ANVISA por meio da propriedade `prov:wasDerivedFrom`. Durante a recuperação, essas associações são consultadas via SPARQL e incorporadas ao contexto fornecido ao LLM para a síntese da resposta.

2.3. Motor de Inferência

Durante a inicialização do sistema, a classe `KGE` submete a base de conhecimento estática a um motor de inferência (`owlrl.DeductiveClosure`). Atuando sob a semântica `OWL-RL`, o motor expande o grafo com novos triplos lógicos. Na prática, isso permite que instâncias declaradas apenas como `onto:SintomaRespiratorio` (como a Tosse) sejam deduzidas automaticamente como `onto:Sintoma`, garantindo que consultas genéricas sobre sintomas recuperem todos os subníveis da hierarquia.

3. Arquitetura do Sistema e GraphRAG

A arquitetura do `OntoTriage` orquestra o LLM (Google Gemini Flash) e o Knowledge Graph em um pipeline GraphRAG, isolando o raciocínio simbólico da geração de texto.




Figura 1. Arquitetura do pipeline GraphRAG do OntoTriage.

Conforme ilustrado na Figura 1, o pipeline GraphRAG é composto por três etapas principais: (1) extração de entidades, (2) consulta ao Knowledge Graph e (3) síntese fundamentada da resposta. O processamento completo inicia com o relato do usuário e termina com a resposta produzida pelo sistema.

1. Extração de Entidades (NER): O relato em linguagem natural do usuário é enviado ao LLM juntamente com o vocabulário controlado (lista de sintomas recuperados do KG). Através de um prompt cuidadosamente elaborado, o modelo atua apenas como extrator, retornando um array JSON com as URIs exatas dos sintomas identificados (ex.: "dor de cabeça" é mapeado para `onto:DorDeCabeca`).
2. Recuperação e Inferência (SPARQL): A classe `KGE` utiliza as URIs extraídas para realizar consultas SPARQL. A primeira consulta identifica e

ranqueia as doenças pelo número de sintomas correspondentes. A segunda consulta extrai o subgrafo de contexto para cada doença: recupera os sintomas esperados, medicamentos contraindicados, a categoria desses medicamentos, e resgata dinamicamente a proveniência (`prov:wasDerivedFrom`) associada à doença e à restrição medicamentosa.

3. Síntese Fundamentada: O subgrafo resultante é convertido em um dicionário estruturado (`kg_context`) e enviado de volta ao LLM. O prompt de síntese instrui o modelo a (i) basear a resposta exclusivamente nas doenças e contraindicações listadas, (ii) citar *apenas* as fontes literais que constam no nó "Fontes_Oficiais_Consultadas" do contexto e (iii) emitir o alerta obrigatório de que o sistema não substitui a avaliação médica.

4. Demonstração e Resultados

Para validar os requisitos propostos, o sistema foi submetido a uma suíte de testes automatizados (unittest), que comprovaram a consistência da inferência OWL-RL e a correta recuperação das entidades PROV-O e hierarquias lógicas via SPARQL.

Adicionalmente, a demonstração interativa do sistema comprova a eficácia da abordagem híbrida. Em um cenário de teste, o sistema recebe a entrada: "Estou com febre alta e dor nas articulações". O motor extrai os conceitos `onto:Febre` e `onto:Artralgia`. A consulta ao KG recupera as doenças que apresentam os sintomas correspondentes e as ordena de acordo com a quantidade de sintomas coincidentes. Nesse caso, Zika e Chikungunya apresentam dois sintomas correspondentes, enquanto Dengue, Gripe e COVID-19 apresentam um sintoma correspondente. Para as doenças recuperadas, o sistema consulta os detalhes e as contraindicações medicamentosas associadas, identificando, entre outras informações, as relações de contraindicação entre Ibuprofeno, Ácido Acetilsalicílico (AAS) e as arboviroses presentes no grafo. O LLM então gera uma resposta em formato de triagem estruturada:

- Identificação: Aponta possíveis correlações com as doenças recuperadas pelo Knowledge Graph, com destaque para as condições que apresentam maior quantidade de sintomas coincidentes.
- Aviso Crítico: Destaca as contraindicações medicamentosas recuperadas do grafo.
- Fundamentação: Exibe textualmente a citação de proveniência (Ministério da Saúde - Protocolos de Manejo Clínico e ANVISA - Bulário Eletrônico), recuperada do Knowledge Graph.

Limitações: Devido à natureza simbólica rígida da consulta SPARQL, a eficácia do sistema é estritamente dependente da etapa inicial de NER (Reconhecimento de Entidades). Descrições de sintomas altamente atípicas ou que escapem da capacidade de abstração do LLM para o vocabulário controlado podem resultar em consultas vazias ao grafo, interrompendo a geração do contexto.

5. Conclusão

O desenvolvimento do OntoTriage atingiu o objetivo de construir um sistema especialista funcional, evidenciando as vantagens da integração entre uma base de conhecimento

simbólica e um modelo generativo. A arquitetura GraphRAG busca mitigar o risco de alucinações ao restringir o contexto factual utilizado pelo LLM às informações recuperadas do Knowledge Graph e ao instruir a síntese a utilizar exclusivamente as doenças, contraindicações e fontes presentes nesse contexto. Nos testes realizados, as respostas produzidas permaneceram fundamentadas nas informações recuperadas do grafo.

A inclusão da ontologia PROV-O mostrou-se importante para a rastreabilidade das informações utilizadas pelo sistema. Ao associar as entidades do Knowledge Graph às fontes oficiais por meio de `prov:wasDerivedFrom` e recuperar essa proveniência dinamicamente via SPARQL, o sistema fornece ao LLM fontes previamente registradas na base de conhecimento para fundamentar a resposta, reduzindo o espaço para a geração de referências não presentes no contexto recuperado.

Como trabalhos futuros, vislumbra-se a expansão automatizada da base de conhecimento a partir da mineração de novos protocolos clínicos e a implementação de buscas híbridas (vetorial e simbólica simultâneas) para flexibilizar a etapa de alinhamento semântico do vocabulário controlado, aumentando a resiliência do sistema frente a ambiguidades da linguagem natural.

Referências

- Agência Nacional de Vigilância Sanitária (ANVISA). Bulário Eletrônico. Disponível em <https://consultas.anvisa.gov.br/#/bulario/>. Acesso em: jul. 2026.
- Brasil. Ministério da Saúde. Guia de Vigilância em Saúde. 6. ed. Brasília: Ministério da Saúde, 2024.
- Edge, D., Trinh, H., Cheng, N., et al. (2024). From Local to Global: A GraphRAG Approach to Query-Focused Summarization. Microsoft Research. Disponível em <https://arxiv.org/abs/2404.16130>.
- W3C. OWL 2 Web Ontology Language Document Overview (Second Edition). W3C Recommendation, 11 December 2012. Disponível em <https://www.w3.org/TR/owl2-overview/>. Acesso em: jul. 2026.
- W3C. PROV-O: The PROV Ontology. W3C Recommendation, 30 April 2013. Disponível em <https://www.w3.org/TR/prov-o/>. Acesso em: jul. 2026.
- W3C. RDF 1.1 Concepts and Abstract Syntax. W3C Recommendation, 25 February 2014. Disponível em <https://www.w3.org/TR/rdf11-concepts/>. Acesso em: jul. 2026.
- W3C. SPARQL 1.1 Query Language. W3C Recommendation, 21 March 2013. Disponível em <https://www.w3.org/TR/sparql11-query/>. Acesso em: jul. 2026.